

RAG Java

Guia paso a paso para ejecutar el software de manera local

Documento paso a paso para ejecutar el proyecto en Windows, macOS y Linux.

1. ¿Qué es RAG Java?

RAG Java es una aplicación local que permite:

- Subir documentos (PDF, DOCX, TXT, etc.)
- Dividirlos en fragmentos (chunks)
- Generar embeddings de forma local (sin enviar datos a la nube)
- Buscar los fragmentos más relevantes mediante similitud coseno
- Exportar un archivo Markdown listo para usar con ChatGPT, Claude, Gemini u otro LLM

Todo funciona en tu computadora. No se requiere conexión a internet después de descargar las dependencias.

2. Requisitos del sistema

Requisito	Versión mínima	Notas
Java JDK	21 o superior	Obligatorio
Git	Cualquier versión reciente	Para clonar el repositorio
Maven	No obligatorio	El proyecto incluye Maven Wrapper (`mvnw`)
Navegador web	Chrome, Firefox, Edge, Safari	Para usar la interfaz gráfica
RAM	4 GB recomendados	Más memoria mejora el rendimiento con muchos arch
Espacio en disco	~500 MB	Incluye dependencias Maven y modelos de embeddin

Verificar Java instalado

Windows (PowerShell o CMD):

```
java -ver
```

macOS / Linux (Terminal):

```
java -ver
```

Debes ver una salida similar a:

```
openjdk v
```

o

```
java vers
```

Si Java no está instalado, descárgalo desde:

- <https://adoptium.net/> (Eclipse Temurin, recomendado)
 - <https://www.oracle.com/java/technologies/downloads/>
-

3. Descargar el proyecto desde GitHub

Opción A - Clonar con Git (recomendado)

Abre una terminal en la carpeta donde quieras guardar el proyecto.

Windows:

```
git clone  
cd rag-ja
```

macOS / Linux:

```
git clone  
cd rag-ja
```

Reemplaza `TU\_USUARIO` por tu usuario u organización de GitHub.

Opción B - Descargar ZIP

1. Entra al repositorio en GitHub
 2. Clic en Code -> Download ZIP
 3. Descomprime el archivo
 4. Abre una terminal dentro de la carpeta rag-java
-

4. Ejecutar la aplicación

El proyecto incluye Maven Wrapper, así que no necesitas instalar Maven manualmente.

Windows

En PowerShell o CMD, dentro de la carpeta del proyecto:

```
.\mvnw.cmd spring-boot:run
```

macOS / Linux

```
chmod +x mvnw  
./mvnw spring-boot:run
```

?Qué ocurre al ejecutar?

1. Maven descarga las dependencias (solo la primera vez; puede tardar varios minutos)
2. Se compila el proyecto
3. Se inicia el servidor en el puerto 8080
4. Verás un mensaje similar a:

Starte

****Importante:**** Deja la terminal abierta mientras uses la aplicación. Para detenerla, presiona `Ctrl + C`.

5. Abrir la interfaz web

Con la aplicación en ejecución, abre tu navegador y visita:

```
http://localhost:8080
```

Verás la interfaz con tres secciones principales:

1. Subir documentos - arrastra o selecciona archivos
2. Documentos indexados - lista de archivos procesados
3. Consulta y exportación - buscar contexto y descargar Markdown

6. Uso paso a paso (interfaz web)

Paso 1 - Indexar documentos

1. Arrastra uno o varios archivos a la zona de carga, o haz clic en Seleccionar archivos
2. Formatos soportados: PDF, DOCX, TXT, HTML, RTF y más (vía Apache Tika)
3. Haz clic en Indexar documentos
4. Espera a que aparezca el mensaje de confirmación con la cantidad de chunks creados

La primera indexación puede tardar más porque el modelo de embeddings se carga en memoria.

Paso 2 - Verificar documentos indexados

En la tabla Documentos indexados verás:

- Nombre del archivo
- Cantidad de chunks generados
- Botón para eliminar un documento del índice

Paso 3 - Realizar una consulta

1. Escribe tu pregunta en el campo Consulta del usuario

- Ejemplo: `""Resume los requisitos técnicos del proyecto""`

2. (Opcional) Ajusta:

- Top K: cantidad máxima de fragmentos a devolver (por defecto: 5)

- Score mínimo: umbral de similitud coseno (por defecto: 0.55)

3. Haz clic en Vista previa para ver los fragmentos encontrados en pantalla

Paso 4 - Descargar Markdown para un LLM

1. Con la consulta escrita, haz clic en Descargar Markdown

2. Se descargará el archivo rag-context.md

3. Abre tu LLM favorito (ChatGPT, Claude, etc.)

4. Sube o pega el contenido de rag-context.md

5. Haz tu pregunta al LLM; usará solo el contexto del archivo

7. Uso alternativo - API REST

Si prefieres la línea de comandos o integrar con otros sistemas:

Verificar que la API funciona

```
curl http://localhost:8080/api/rag/health
```

Subir documentos

Windows (PowerShell):

```
curl.exe  
"files=@C
```

macOS / Linux:

```
curl -X P
```

Buscar fragmentos (JSON)

```
curl -X POST http://localhost:8080/api/rag/search ^  
-H "Content-Type: application/json" ^  
-d '{"query": "\?Cómo configurar el sistema?", "topK": 5, "minScore": 0.55}'
```

(En macOS/Linux usa \ en lugar de ^ para continuar la línea.)

Descargar Markdown

```
curl -X POST http://localhost:8080/api/rag/export ^  
-H "Content-Type: application/json" ^  
-d '{"query": "Resume los requisitos del proyecto"}' ^  
-o rag-context.md
```

8. Compilar un JAR ejecutable (opcional)

Para distribuir o ejecutar sin Maven en cada arranque:

Windows:

```
. \mvnw.cmd
java -jar
```

macOS / Linux:

```
./mvnw cl
java -jar
```

Luego abre `http://localhost:8080` como de costumbre.

9. Configuración avanzada

El archivo `src/main/resources/application.yml` permite ajustar:

```
server:
  port: 8080          # Cambiar puerto si 8080 está ocupado

rag:
  chunk:
    size: 800         # Tamaño aproximado de cada chunk (caracteres)
    overlap: 100      # Solapamiento entre chunks
  search:
    default-top-k: 5
    default-min-score: 0.55
```

Después de modificar la configuración, reinicia la aplicación.

10. Solución de problemas

"java no se reconoce como comando"

- Java no está instalado o no está en el PATH del sistema
- Instala JDK 21+ y reinicia la terminal
- En Windows, verifica que `JAVA_HOME` apunte al JDK

"Puerto 8080 already in use"

- Otro programa usa el puerto 8080
- Cierra la otra aplicación o cambia el puerto en `application.yml`:

```
server:
  port:
```

- Accede entonces a `http://localhost:8081`

La descarga de dependencias falla o es muy lenta

- Verifica tu conexión a internet (solo necesaria la primera vez)
- Si usas proxy corporativo, configura Maven con las variables de proxy adecuadas
- Reintenta: `.\mvnw.cmd clean spring-boot:run`

"No se extrajo contenido del archivo"

- El archivo puede estar vacío, protegido o en un formato no soportado
- Prueba con un archivo TXT o PDF con texto seleccionable (no solo imagen escaneada)

No se encuentran fragmentos en la búsqueda

- Reduce el Score mínimo (por ejemplo, a 0.40)
- Aumenta Top K
- Verifica que los documentos relevantes estén indexados
- Reformula la consulta con términos más específicos

Error de memoria (OutOfMemoryError)

- Cierra otras aplicaciones pesadas
- Indexa menos archivos a la vez
- Ejecuta con más memoria:

(En macOS/Linux: `export JAVA_OPTS=-Xmx2g`)

```
set JAVA_OPTS=-Xmx2g
.\mvnw.cmd
```

11. Ejecutar tests (opcional)

Para verificar que todo funciona correctamente:

Windows:

```
.\mvnw.cmd test
```

macOS / Linux:

```
./mvnw test
```

Debes ver BUILD SUCCESS al finalizar.

12. Resumen rápido

Paso	Acción
1	Instalar Java 21+
2	Clonar o descargar el repositorio
3	Ejecutar <code>.\mvnw.cmd spring-boot:run</code> (Windows) o
4	Abrir <code>http://localhost:8080</code>
5	Subir documentos y hacer clic en Indexar documentos
6	Escribir consulta y descargar rag-context.md
7	Usar el Markdown con tu LLM preferido

13. Soporte

Si encuentras un problema:

1. Revisa la sección Solución de problemas de esta guía
2. Consulta el archivo README.md del repositorio
3. Abre un Issue en GitHub describiendo el error, tu sistema operativo y la versión de Java

Documento generado para el proyecto RAG Java - Ejecución local con Spring Boot, embeddings locales y exportación Markdown.